

Optimizacija več-agentnega iskanja poti z uvedbo lokalnih vodij

Andraž Šošterič

andraz.sosteric@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Nejc Fras

nejc.fras@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

David Lipavec

david.lipavec@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Tadej Teršek

tadej.tersek@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

POVZETEK

V tem delu obravnavamo problem večagentnega iskanja poti MAPF, kjer primerjamo centralizirane in decentralizirane algoritme, ter predlagamo svoj hibridni pristop z lokalnimi vodijami (*local leaders*). Algoritem agente dinamično razporeja v lokalne skupine, znotraj katerih vodja koordinira gibanje s prioriteto razrešitve konfliktov in algoritmom A*. Predlagani pristop primerjamo s centraliziranimi algoritmi LaCAM in PBS ter decentraliziranimi algoritmoma Follower in MATS-LP na standardiziranih zbirkah MovingAI in POGEMA. Local Leaders dosledno dosega nižji SoC kot LaCAM in PBS ($\approx 9\%$ pri 64 agentih), hkrati pa je 100–400× hitrejši od MATS-LP pri lifelog scenarijih.

KLJUČNE BESEDE

centralizirano načrtovanje poti, distribuirano načrtovanje poti, usklajevanje agentov, izogibanje trkom, optimizacija poti

1 UVOD

V tem članku obravnavamo problem več-agentnega iskanja poti (Multi-Agent Path Finding / MAPF), ki se v praksi pojavlja v številnih domenah, kot so robotizirana skladišča, avtonomna vozila, inteligentni transportni sistemi in drugi logistični sistemi. Gre za temeljni problem koordinacije več avtonomnih enot v skupnem prostoru, kjer mora vsak agent doseči svoj cilj brez trkov z drugimi agenti ali ovirami.

Cilj problema je načrtovati poti za množico agentov v diskretnem prostoru tako, da se izognemo medsebojnim konfliktom in hkrati optimiziramo določene metrike, kot sta skupni čas izvajanja (ang. *makespan*) ali vsota dolžin poti (ang. *sum of costs*) [8].

Repozitorij z izvorno kodo projekta je na voljo na našem github repozitoriju¹.

V nadaljevanju bomo primerjali centralizirane metode, katerih predstavnik sta LaCAM in PBS, ki načrtujejo poti za vse agente z uporabo globalnega pogleda na problem, ter decentralizirane

pristope, kot sta Follower in MATS-LP, kjer posamezni agenti sprejemajo odločitve lokalno brez centralnega nadzora in imajo pregled le nad svojo okolico.

Na ta način bomo analizirali ključne razlike med obema paradigama z vidika učinkovitosti, skalabilnosti in kakovosti rešitev. Centralizirani pristopi praviloma zagotavljajo bolj optimalne rešitve, vendar slabše skalirajo z naraščajočim številom agentov, medtem ko decentralizirani pristopi omogočajo boljšo razširljivost, vendar pogosto na račun kakovosti rešitev.

Kot glavni referenčni algoritem izberemo delo *LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding* [5], ki predstavlja sodoben in učinkovit centraliziran pristop k reševanju problema MAPF. Izbrani članek služi kot referenčna osnova za našo analizo, saj ponuja dobro ravnotežje med učinkovitostjo in skalabilnostjo ter omogoča relativno enostavno reprodukcijo eksperimentov.

LaCAM bomo uporabili kot predstavnika centraliziranih metod, s katerim bomo primerjali decentralizirane pristope, kot sta Follower in MATS-LP, ter tako sistematično analizirali razlike med globalnim in lokalnim načrtovanjem poti.

1.1 Definicija problema

Stern et al. [8] definirajo problem več-agentnega iskanja poti (Multi-Agent Path Finding - MAPF) kot trojico

$$\langle G, s, t \rangle,$$

kjer je $G = (V, E)$ neusmerjen graf, pri čemer V predstavlja množico vozlišč, E pa množico povezav.

Podana je množica agentov $A = \{1, 2, \dots, k\}$. Funkcija

$$s : \{1, \dots, k\} \rightarrow V$$

preslika vsakega agenta v njegovo začetno vozlišče, funkcija

$$t : \{1, \dots, k\} \rightarrow V$$

pa v njegovo ciljno vozlišče.

Naj bo $\pi_i[t] \in V$ položaj agenta i v diskretnem času $t \in \mathbb{N}_{\geq 0}$. Pri vsakem koraku t se agent i lahko premakne v sosednje vozlišče ali

¹<https://github.com/Asos75/MultiAgent>

ostane na trenutnem, tj.

$$\pi_i[t+1] \in \text{neigh}(\pi_i[t]) \cup \{\pi_i[t]\},$$

kjer je $\text{neigh}(v)$ množica vozlišč, sosednjih vozlišču $v \in V$ [5].

Po Okamuri [5] se mora agent izogibati naslednjim vrstam konfliktov:

- **Vozliščni konflikt:** Do vozliščnega konflikta (ang. vertex conflict) pride, če nameravata π_i in π_j zasedeti isto vozlišče v istem trenutku, torej obstaja časovni korak t , da velja $\pi_i[t] = \pi_j[t]$. [8]
- **Zamenjalni konflikt:** Do zamenjalnega konflikta (ang. swap conflict) pride, če nameravata π_i in π_j zamenjati svoji poziciji v istem trenutku, torej obstaja časovni korak t , da velja $\pi_i[t] = \pi_j[t+1] \wedge \pi_j[t] = \pi_i[t+1]$ [8].

Rešitev MAPF za instance, omenjene zgoraj, je množica brezkonfliktnih poti $\{\pi_1, \dots, \pi_k\}$ takih, da obstaja časovni korak $T \in \mathbb{N}_{\geq 0}$, kjer agent doseže cilj. [5]

2 SORODNA DELA

V tem razdelku izpostavimo ključna dela s področja več-agentnega iskanja poti, ki dopolnjujejo in razširjajo pogled iz uvoda. Pri vsakem delu na kratko povemo, kaj je njegova glavna ideja in kakšen doprinos ima k našemu eksperimentu.

2.1 Centralizirani pristopi

EECBS [4] je nadgradnja klasičnega CBS, ki ohrani dvonivojsko iskanje, hkrati pa z *Explicit Estimation Search* in uteževanjem omogoča nadzorovano suboptimalnost (uporabnik nastavi kompromis med kakovostjo in časom). Avtorji poročajo o bistveno boljši skalabilnosti na večjih instancah ob majhni, dokazljivo omejeni degradaciji kakovosti rešitve. EECBS uporabimo kot referenčno izhodišče za razumevanje kompromisa »hitrost vs. kvaliteta« pri centraliziranih metodah; njegove ideje utemeljijo, zakaj v evalvaciji poleg kakovosti (SoC/makespan) spremljamo tudi čas izvajanja in skalabilnost.

CBSH2 [3] izboljša CBS z močnejšimi heuristikami in tehniko *disjoint splitting*, ki z uvedbo pozitivnih omejitev zmanjša podvajanje iskanja in s tem velikost iskalnega drevesa. Rezultat je hitrejšo reševanje in boljša skalabilnost ob ohranjeni rešitveni kakovosti tipične za CBS-družino. CBSH2 obravnavamo kot dodatno referenco znotraj centraliziranih metod, ki pokaže, da so izboljšave pogosto posledica boljšega upravljanja konfliktov; to nam pomaga pri interpretaciji rezultatov LaCAM/PBS (kjer tudi ciljamo na učinkovitejšo obravnavo konfliktov), če opazimo razlike predvsem v času in ne v SoC.

2.2 Decentralizirani pristopi

Follower [1] je decentraliziran pristop za *lifelong* MAPF, ki kombinira (i) heuristični planer (npr. A^* nad statičnimi ovirami), ki generira »razpršene« poti z namenom zmanjšanja zasičenosti ozkih grl, in (ii) naučeno politiko sledenja, ki lokalno reagira na druge agente in se izogiba trkom. Izvajanje je povsem lokalno (brez centralnega koordinatorja), zato metoda dobro skalira, vendar je kakovost poti odvisna od lokalnih informacij in stabilnosti naučene politike. *Follower* je eden naših glavnih decentraliziranih primerjalnih algoritmov; z njim ovrednotimo, kako se učeni, lokalni pristopi

primerjajo s centraliziranimi LaCAM/PBS in z našim hibridnim pristopom z lokalnimi vodji.

Decentralized Monte Carlo Tree Search for Partially Observable Multi-agent Pathfinding [7] predlaga decentralizirano reševanje *lifelong* MAPF pri delni opazljivosti: vsak agent iz lokalnih opazovanj zgradi intrinzični (lokalni) MDP in na njem izvaja MCTS, ki ga dodatno usmerja nevronska politika. S simulacijami v drevesu agenti ocenjujejo kratkoročne interakcije z bližnjimi agenti, koordinacija pa nastaja implicitno (brez eksplicitne komunikacije ali centralnega koordinatorja), kar vodi do dobre skalabilnosti. delo utemeljuje našo izbiro decentraliziranih primerjalnih metod na POGEMA (delna opazljivost) in je neposredno relevantno za komponento MATS-LP v naši primerjavi, kjer želimo videti, ali »lookahead« (MCTS) izboljša pretočnost in robustnost glede na bolj reaktivne politike.

PRIMAL2 [2] je zgodnje, vplivno delo, ki pokaže, da je mogoče MAPF reševati z decentraliziranimi politikami na osnovi lokalnih opazovanj, naučenimi s kombinacijo *imitation learning* (iz centraliziranih planerjev) in *reinforcement learning*. Pristop zelo dobro skali, vendar pogosto žrtvuje optimalnost in lahko povzroča neusklajenosti v gostih scenarijih. *PRIMAL2* uporabljamo kot kontekst za interpretacijo rezultatov učenih decentraliziranih metod (*Follower*/MATS-LP/SCRIMP): če pri njih opazimo slabši SoC, je to pričakovan trade-off, ki ga literatura že izpostavlja.

SCRIMP [9] uvede eksplicitno komunikacijo med agenti z uporabo transformer arhitekture in pozornostnega mehanizma, kar omogoča učinkovitejšo koordinacijo tudi pri zelo omejenem vidnem polju. S tem pristop preseže omejitve povsem nekomunikacijskih lokalnih politik, hkrati pa ohrani decentralizirano izvajanje in dobro skalabilnost. *SCRIMP* služi kot motivacija za naš »hibridni« pogled (lokalni vodje): kaže, da lahko dodaten koordinacijski signal (komunikacija ali posredno usklajevanje) izboljša pretočnost; naš pristop to doseže z lažjim mehanizmom vodij, ki ga lahko primerjamo z relacijo med čisto lokalnimi in bolj koordiniranimi pristopi.

2.3 Primerjalne platforme

POGEMA [6] ponuja standardizirano platformo za evalvacijo MAPF algoritmov v (delno) opazljivih okoljih, z generatorjem instanc in enotnimi metrikami ter protokolom izvajanja. Omogoča pošteno in ponovljivo primerjavo različnih pristopov. *POGEMA* je naše glavno evalvacijsko ogrodje, zato se metodologija, metrike in primerjava rezultatov neposredno opirajo na to delo.

3 METODOLOGIJA

V tem poglavju bomo predstavili metodologijo vrednotenja in primerjanja izbranih algoritmov za problem večagentnega iskanja poti. Cilj eksperimentalnega dela je primerjati centralizirane pristope, kot sta LaCAM in PBS, z decentraliziranimi pristopi *Follower* in MATS-LP ter ovrednotiti predlagani hibridni pristop z lokalnimi vodji.

3.1 Experimentalno okolje

Za primerjalno okolje bomo uporabili knjižnico *POGEMA* [6], ki omogoča standardizirano evalvacijo MAPF algoritmov v delno opazljivih okoljih, ter to kombinirali z *MovingAI* [8] knjižnico zemljevidov za testiranje agentov.

POGEMA je dostopna kot standardna Python knjižnica, medtem ko so implementacije posameznih algoritmov pridobljene iz uradnih repozitorijev avtorjev izbranih člankov. Ker različni algoritmi uporabljajo različne vhodne formate in interne predstavitve okolja, je bilo potrebno za vsako implementacijo razviti poseben prilagoditveni sloj (*adapter*), ki omogoča vključitev algoritma v skupno evalvacijsko ogrodje.

3.2 Metrike

Sum-of-Costs (SoC) je vsota časovnih korakov, ki jih vsi agenti porabijo za doseg svojih ciljnih vozlišč [8]:

$$\text{SoC} = \sum_{i=1}^k |\pi_i|,$$

kjer je $|\pi_i|$ dolžina poti agenta i . Nižja vrednost pomeni učinkovitejšo rešitev.

SoC je ena izmed najpogostejše uporabljenih metrik v MAPF literaturi [8], kar omogoča neposredno primerjavo z obstoječimi deli. Metrika meri skupni strošek kot vsoto dolžin poti vseh agentov in s tem neposredno zajame celostno učinkovitost sistema.

Metrika je še posebej primerna za one-shot scenarije, saj minimizacija SoC ustreza cilju minimizacije skupne porabe časa oziroma virov. Hkrati kaznuje neučinkovite poti posameznih agentov, kar spodbuja iskanje globalno učinkovitih rešitev. SoC bomo zato uporabili za vrednotenje algoritmov LaCAM in PBS na zbirki MovingAI.

Makespan je čas, ki ga porabi najdaljša pot med vsemi agenti, torej maksimum nad vsemi $|\pi_i|$ [8]:

$$\text{makespan} = \max_{i \in \{1, \dots, k\}} |\pi_i|.$$

Metrika odraža skupno trajanje reševanja instance in je primerna za scenarije, kjer je ključen vzporedni zaključek vseh agentov. Makespan je uveljavljena metrika v MAPF literaturi [8] in je še posebej relevantna v praktičnih aplikacijah, kjer je ključen vzporedni zaključek vseh agentov.

Makespan je pri primerjavi centraliziranih algoritmov nujna dopolnitev k SoC, saj sama vsota stroškov namreč ne razkrije, ali posamezen agent morda bistveno zavlačuje celotno skupino. Z vključitvijo obeh metrik tako dobimo celovitejšo in bolj zanesljivo oceno učinkovitosti algoritma v realnih pogojih.

Stopnja uspeha (Success Rate) meri delež instanc, pri katerih vsi agenti uspešno dosežejo svoje cilje znotraj predvidenega časovnega horizonta [6].

Stopnja uspeha je primarna metrika platforme POGEMA in skupaj s pretokom (ang. throughput) tvori osnovo za vrednotenje na tej platformi [6]. Zasnovana je posebej za vrednotenje decentraliziranih metod v delno opazljivih okoljih. Metrika je za naš eksperiment ključna, saj za razliko od SoC in makespana meri tudi robustnost algoritma oziroma njegovo sposobnost, da instanco v celoti reši kljub omejenim lokalnim opazovanjem.

Čas načrtovanja merimo kot skupni čas izvajanja algoritma na posamezni instanci. Ta metrika je še posebej pomembna pri primerjavi med kategorijama, saj centralizirani načrtovalci tipično porabi več časa za globalno načrtovanje, kot decentralizirani agenti.

Čas načrtovanja je v praktičnih aplikacijah enako pomemben kot kakovost rešitve, saj algoritem z optimalno potjo, a dolgim časom načrtovanja, v realnih sistemih ni uporaben. Ta metrika nam tako omogoča primerjavo med pristopoma z vidika razširljivosti in praktične uporabnosti.


3.3 Protokol primerjave

Primerjavo bomo izvedli na dveh ravneh:

- (1) **Znotraj kategorije:** LaCAM in PBS primerjamo na MovingAI zbirki po metrikah SoC, makespan in čas načrtovanja. Follower in MATS-LP primerjamo na POGEMA zbirki po metrikah throughput in stopnja uspeha.
- (2) **Med kategorijama na skupni zbirki:** Obe kategoriji bomo primerjali med seboj na skupni zbirki, kjer bomo primerjali prej navedene metrike.

3.4 Uvedba lokalnih vodij

Glavni prispevek tega dela je predlagana nadgradnja obstoječih pristopov, ki uvaja koncept *lokalnih vodij*. Gre za hibridni algoritem *Local Leaders*, ki združuje prednosti centraliziranega in decentraliziranega pristopa. Algoritem deluje lokalno, na ravni agenta, brez vnaprejšnjega načrtovanja in deluje v petih korakih (sl. 1).



Slika 1: Diagram poteka algoritma Local Leaders: dinamično oblikovanje skupin, določitev vodje, A* načrtovanje in prioriteta razrešitev konfliktov.

1. *Oblikovanje skupin*. Na začetku vsakega koraka, se agenti razdelijo v skupine. Pravilo za deljenje je preprosto in deterministično: Agent i postane *vodja*, če nobeden od agentov z nižjim ID-jem ne leži znotraj razdalje r_{comm} (Razdalja se izračuna po metodi Manhattan). Procesiranje agentov, od najnižjega do najvišjega ID-ja zagotovi konsistentno particijo brez dvoumnosti. Pri tem se pa particija se spremeni vsak korak, tako da je članstvo v skupini dinamično glede na trenutno postavitev.

2. *Željena celica (A^*)*. Vsak agent zase neodvisno izvede algoritem A^* od svojega položaja, do cilja, pri čimer gleda le na statične ovire. Agent na tej točki ignorira ostale agente. Rezultat tega koraka, je prva celica najkrajše poti, to je celica kamor se agent *želi* premakniti. Agenti, ki so obstali $\geq t_{\text{esc}}$ korakov preidejo v *način pobega*, kjer namesto A^* izberejo naključno prosto sosednjo celico, s čimer prekinje tesnobne zastoje v hodnikih.

3. *Prioritetna razrešitev konfliktov*. Agenti se obdelajo v vrstnem redu prioritete:

- (1) agenti v načinu pobega (najvišja prioriteta),
- (2) vodje skupin,
- (3) sledilci.

Znotraj vsake ravni je prednost pri agentih z nižjim ID-jem. Za vsakega agenta se preverita *vozliščni* in *zamenjalni* konflikt. V primeru konflikta se agent pomakne v najbližjo prosto, še nezaseženo celico. Ker se agenti z višjo prioriteto potrdijo prej, nižjeprioritetni agenti vedno vidijo zasedene celice in se jim izognejo, tako se izognemo konfliktom v fizikalnem koraku.

4. *Posodobitev števca zastoja*. Agent, ki se ni premaknil, poveča števec zastoja; agent, ki se je premaknil, ga ponastavi na nič.

5. *Implementacija*. Algoritem je implementiran v Pythonu za integracijo z okoljem POGEMA in MovingAI, ter v C++ (prek pybind11) za hitrejšo izvajanje. Parametri uporabljeni za testiranje so $r_{\text{comm}} = 7$, $t_{\text{esc}} = 8$.

Lokalni vodja nima globalnega pogleda nad celotnim okoljem, temveč razpolaga le z informacijami o agentih znotraj svoje skupine in njihove neposredne okolice. Na ta način se bistveno zmanjša kompleksnost načrtovanja v primerjavi s centraliziranimi algoritmi, hkrati pa se ohrani višja stopnja koordinacije kot pri popolnoma decentraliziranih pristopih.

Hipoteza našega dela je, da lahko takšen hibridni pristop doseže boljše razmerje med kakovostjo rešitev in časom načrtovanja kot obstoječi centralizirani ali decentralizirani pristopi posebej. Pričakujemo nižji *makespan* in višjo stopnjo uspeha kot pri decentraliziranih metodah ter bistveno krajši čas načrtovanja kot pri popolnoma centraliziranih algoritmihih.

4 EKSPERIMENT IN ANALIZA REZULTATOV

Po začetni validaciji implementacij smo zasnovali lasten eksperiment, ki primerja centralizirane, decentralizirane in hibridni pristop z lokalnimi vodji. Namen eksperimenta je preveriti ali lahko uvedba lokalnih vodij izboljša razmerje med kakovostjo rešitev in časom načrtovanja.

Experimente izvajamo na standardiziranih zemljevidih iz zbirk MovingAI in POGEMA, na različnih velikostih zemljevidov, gostotah agentov in scenarijih. Tu so najbolj zanimivi scenariji z visoko gostoto agentov, kjer se razlike med rešitvami najbolj pokažejo.


4.0.1 *Testne instance*. Uporabljamo tri glavne tipe okolij:

- **Odperte mreže** (*random grids*) – okolja z malo ovirami, kjer je večina konfliktov posledica visoke gostote agentov.
- **Labirinti** (*mazes*) – okolja z ozkimi prehodi in številnimi lokalnimi ozkimi grli, kjer je koordinacija agentov bistveno zahtevnejša.
- **Skladiščni scenariji** (*warehouse maps*) – realistične postavitve, podobne robotiziranim skladiščem, kjer se agenti pogosto srečujejo na križiščih in v ozkih hodnikih.

Za vsako vrsto okolja izvajamo eksperimente pri različnih številih agentov (od 20 do 1000 agentov, odvisno od velikosti zemljevida), z različnimi konfiguracijami. Vsaka konfiguracija se izvede večkrat z različnimi scenariji, ki vključujejo začetne in ciljne pozicije agentov, rezultati pa se povprečijo, da zmanjšamo vpliv posameznih naključnih primerov.

4.1 Vsota stroškov (SoC)


Slika 2 prikazuje vsoto stroškov za LaCAM, PBS in Local Leaders na treh tipih zemljevidov pri različnih številih agentov.



Slika 2: Vsota stroškov (SoC): LaCAM, PBS in Local Leaders na naključnih, labirintnih in skladiščnih zemljevidih. Napake kažejo standardno deviacijo čez 3 semena.

Ključna ugotovitev je, da tako PBS kot Local Leaders dosledno dosega *nižji* SoC kot LaCAM pri vseh tipih zemljevidov. Na naključnih zemljevidih pri 8 agentih so vrednosti skoraj identične (LaCAM: 168, PBS: 167, LL: 167), pri 64 agentih pa Local Leaders doseže SoC 2716, PBS pa 2715, medtem ko LaCAM doseže 2974, kar je $\approx 9\%$ manj za oba. Na skladiščnih zemljevidih je prihranek pri 32 agentih $\approx 9\%$ (PBS: 5337, LL: 5338 vs. LaCAM: 5844). Na labirintnih zemljevidih PBS doseže SoC 782 pri 16 agentih (vs. LaCAM 881, $\approx 11\%$ manj), Local Leaders pa 846 ($\approx 4\%$ manj, le pri uspešnih instancah). Rezultat je nekoliko presenetljiv, saj LaCAM minimizira SoC globalno, medtem ko PBS in Local Leaders delujeta lokalno oziroma s prioriteto razrešitvijo, vzrok tiči v tem, da lokalna koordinacija pogosto prinese krajše učinkovite poti kot globalni iskalni algoritem.


4.2 Makespan



Slika 3: Makespan: LaCAM, PBS in Local Leaders. Na naključnih in skladiščnih zemljevidih so vsi trije algoritmi praktično identični; na labirintih PBS doseže makespan 109 pri 16 agentih (vs. LaCAM 105), Local Leaders pa 134, kar je posledica delno neuspešnih instanc.

Slika 3 kaže, da je makespan vseh treh algoritmov na naključnih in skladiščnih zemljevidih skoraj enak. Na naključnih zemljevidih z 8 agenti so vrednosti identične (LaCAM: 41, PBS: 42, LL: 41), pri 64 agentih pa vsi dosežejo makespan 95–96. Na labirintih PBS ohranja 100 % uspešnost in doseže makespan 109 pri 16 agentih (LaCAM: 105), torej le minimalno višje. Izjema je Local Leaders: pri 16 agentih doseže makespan 134, ker uspešno reši le 50 % instanc (povprečje zajema le uspešne poskuse). PBS tako zapolni vrzel, ki jo Local Leaders pušča v scenarijih z ozkimi hodniki.

4.3 Čas izvajanja




Slika 4: Čas izvajanja v logaritemski skali. Levi trije paneli: čas načrtovanja LaCAM, PBS in Local Leaders na MovingAI (ms). Desni panel: čas celotne epizode MATS-LP vs. Local Leaders vs. Follower na POGEMA (s, naključni zemljevidi, 0 % ovir).

Slika 4 razkrije eno ključnih razlik med pristopi. Na MovingAI LaCAM porabi manj kot 1 ms za manjše instance in do 128 ms za 32 agentov na skladiščnih zemljevidih. PBS je le malce počasnejši: 0,3–20 ms za vse scenarije, torej blizu LaCAM, a bistveno hitrejši od Local Leaders, ki deluje *online* (A^* za vsakega agenta pri vsakem koraku) in porabi 44–961 ms za naključne ter 188–3203 ms za skladiščne scenarije. PBS tako ponuja najboljše razmerje med kakovostjo rešitve in hitrostjo med vsemi tremi one-shot algoritmi.

Desni panel primerja čas epizode na POGEMA. Tu je razlika dramatična: MATS-LP potrebuje 48 s (8 agentov) do 416 s (32 agentov) za eno epizodo 512 korakov. Local Leaders opravi isto epizodo v 0,26–0,97 s, kar je 100–400× hitreje. Follower (naučena RL politika) leži med njima s 2–7 s na epizodo.

4.4 Stopnja uspeha in pretočnost na POGEMA




Slika 5: Levo: stopnja uspeha LaCAM, PBS in Local Leaders na MovingAI one-shot scenarijih. Desno: lifelong pretočnost MATS-LP, Local Leaders in Follower na POGEMA (naključni zemljevidi, 0 % ovir).

Slika 5 prikazuje dve dimenziji primerjave. V levem delu so stopnje uspeha na MovingAI: na naključnih in skladiščnih zemljevidih vsi trije algoritmi dosežejo 100 % pri vseh gostotah agentov. Na labirintnih zemljevidih LaCAM in PBS vedno uspeša, medtem ko Local Leaders dosega le 67 % (8 agentov) oziroma 50 % (16 agentov). PBS tukaj izrazito prednjači, ozkih hodnikov ne rešuje reaktivno, ampak z optimalnim iskanjem, ki zagotovi pot za vsakega agenta. To je primarna prednost PBS pred Local Leaders v gostih labirintnih scenarijih.

Desni panel prikazuje lifelong pretočnost (cilji/korak) na POGEMA. Rezultati prikazujejo C++ implementacijo Local Leaders, ki je po pretočnosti primerljiva s Python različico, a bistveno hitrejša pri izvedbi. MATS-LP doseže 0,61 (8 agentov), 1,18 (16) in 2,26 (32 agentov). Local Leaders je tik zadaj: 0,57, 1,13 in 2,15, kar je 94–96 % pretočnosti MATS-LP. Follower dosega nižje vrednosti (0,36, 0,76, 1,41).

4.5 Primerjava pretočnosti pri 30 % ovirah




Slika 6: Lifelong pretočnost MATS-LP, Local Leaders in Follower na naključnih zemljevidih pri 0 % (levo) in 30 % (desno) gostoti ovir. Rezultati Local Leaders so iz C++ implementacije. Pri 30 % ovirah Local Leaders občutno degradira pri 16 in 32 agentih.

Slika 6 kaže, kako gostota ovir vpliva na vsak algoritem. Pri 0 % ovirah so vse tri krivulje blizu skupaj in dobro skalirajo z naraščajočim številom agentov. Pri 30 % ovirah se slika bistveno spremeni: MATS-LP ohranja razumno pretočnost (0,36–0,90), Follower je pri 32 agentih primerljiv z MATS-LP (0,94), Local Leaders pa bistveno pade: pri 16 agentih doseže zgolj 0,28, pri 32 agentih pa 0,14. Gosto posejane ovire ustvarjajo ozke hodnike, v katerih se dva agenta

vzajemno blokirata. Mehanizem naključnega pobega (*escape mode*) takšnih cikličnih zastojev ne rešuje zanesljivo.


4.6 SoC overhead razmerje



Slika 7: Razmerje SoC (Local Leaders / LaCAM) po tipu zemljevida. Vrednost pod 1 pomeni, da Local Leaders doseže nižji SoC kot LaCAM.

Slika 7 nazorno prikaže, da Local Leaders pri vseh tipih zemljevidov in pri vseh preizkušanih gostotah agentov doseže nižji SoC kot LaCAM (razmerje $< 1,0$). Na naključnih zemljevidih razmerje pada z naraščajočim številom agentov: od 0,994 (8 agentov) do 0,913 (64 agentov). Na skladiščnih zemljevidih je razmerje med 0,888 (8 agentov) in 0,913 (32 agentov), kar nakazuje, da lokalna koordinacija v regularnih skladiščnih vzorcih učinkoviteje izkorišča strukturo prostora. Na labirintnih zemljevidih razmerje niha (0,994 pri 4, $\approx 0,924$ pri 8, $\approx 0,960$ pri 16 agentih), a ostaja pod 1,0.

4.7 Pretočnost po tipu zemljevida



Slika 8: Lifelong pretočnost MATS-LP in Local Leaders po tipu zemljevida (naključni, labirint, skladišče). Na skladiščnih zemljevidih Local Leaders dosega do 7-kratno višjo pretočnost kot MATS-LP.

Slika 8 primerja pretočnost na vseh treh tipih zemljevidov. Na naključnih in labirintnih je MATS-LP pred Local Leaders, pri čemer razlika narašča z gostoto agentov (MATS-LP: 0,906, LL: 0,237 pri 32 agentih v labirintu). Toda na *skladiščnih* zemljevidih se vlogi zamenjata: Local Leaders doseže pretočnost 1,14 (32 agentov) oziroma 1,96 (96 agentov), medtem ko MATS-LP doseže le 0,11 oziroma 0,28. To je ≈ 10 -kratna prednost Local Leaders. Vzrok je v tem, da MATS-LP v širokih koridorjih skladišča MCTS iskanje postane izjemno računsko zahtevno (do 1240 s na epizodo), medtem ko greedy A^* v takih prostorih deluje brez zastojev in je 400-krat hitrejši.

4.8 Povzetek rezultatov

Tabela 1: Povzetek primerjave po metrikah in tipih evaluacije. ++ zelo dobro, + dobro, ~ primerljivo, - slabo, – zelo slabo.

Metrika	LaCAM	LL	MATS-LP	Follower
SoC (one-shot)	~	+	-	-
Makespan (one-shot)	+	+	-	-
Čas načrtov. (MovingAI)	++	-	-	-
Stopnja uspeha (random)	++	++	-	-
Stopnja uspeha (maze)	++	-	-	-
Pretočnost (0 % ovire)	-	~	+	~
Pretočnost (30 % ovire)	-	--	+	~
Pretočnost (warehouse)	-	++	-	-
Čas epizode (POGEMA)	-	++	-	+

Preglednica 1 povzema primerjavo. Local Leaders se izkaže kot učinkovit hibridni pristop: na one-shot scenarijih dosega primerljivo ali boljše kakovost rešitev kot LaCAM, na lifelong scenarijih se enakovredno kosa z MATS-LP na odprtih okoljih, na skladiščnih okoljih pa ga bistveno prekaša. Primarne slabosti so visoka gostota ovir (30 % ovir) ter ozki hodniki labirintov, kjer mehanizem naključnega pobega ne zadostuje.

LITERATURA

- [1] Anton Andreychuk, Konstantin Yakovlev, Alexey Skrynnik, and Aleksandr Panov. 2024. Follower: Learning to Solve Decentralized Lifelong Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*. AAAI Press.
- [2] Mehul Damani, Zhiyao Luo, Emerson Wenzel, and Guillaume Sartoretti. 2021. PRIMAL₂: Pathfinding via Reinforcement and Imitation Multi-Agent Learning – Lifelong. *IEEE Robotics and Automation Letters* 6, 2 (2021), 2666–2673. <https://doi.org/10.1109/LRA.2021.3062803>
- [3] Jiaoyang Li, Daniel Harabor, Peter J. Stuckey, Ariel Felner, Hang Ma, and Sven Koenig. 2019. Disjoint Splitting for Multi-Agent Path Finding with Conflict-Based Search. 29 (Jul. 2019), 279–283. <https://doi.org/10.1609/icaps.v29i1.3487>
- [4] Jiaoyang Li, Wheeler Ruml, and Sven Koenig. 2021. EECBS: A Bounded-Suboptimal Search for Multi-Agent Path Finding. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*. 12353–12362. <https://doi.org/10.1609/aaai.v35i14.17466>
- [5] Keisuke Okumura. 2023. LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37. AAAI Press, 11655–11662. <https://doi.org/10.1609/aaai.v37i10.26377>
- [6] Alexey Skrynnik, Anton Andreychuk, Anatolii Borzilov, Alexander Chernyavskiy, Konstantin Yakovlev, and Aleksandr Panov. 2025. POGEMA: A Benchmark Platform for Cooperative Multi-Agent Pathfinding. In *The Thirteenth International Conference on Learning Representations*.
- [7] Alexey Skrynnik, Anton Andreychuk, Konstantin Yakovlev, and Aleksandr Panov. 2024. Decentralized Monte Carlo Tree Search for Partially Observable Multi-Agent Pathfinding. In *Proceedings of the Thirty-Eighth AAAI Conference on Artificial Intelligence (AAAI-24)*. AAAI Press.
- [8] Roni Stern, Nathan Sturtevant, Ariel Felner, Sven Koenig, Hang Ma, Thayne Walker, Jiaoyang Li, Dor Atzmon, Liron Cohen, T. Kumar, and Eli Boyarski. 2021. Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks. *Proceedings of the International Symposium on Combinatorial Search* 10 (09 2021), 151–158. <https://doi.org/10.1609/socs.v10i1.18510>
- [9] Yutong Wang, Bairan Xiang, Shao Huang, and Guillaume Sartoretti. 2023. SCRIMP: Scalable Communication for Reinforcement- and Imitation-Learning-Based Multi-Agent Pathfinding. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. <https://doi.org/10.1109/IROS55552.2023.10341379>