Primerjava centraliziranega in distribuiranega več-agentnega iskanja poti

Andraž Šošterič
andraz.sosteric@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

David Lipavec
david.lipavec@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Nejc Fras
nejc.fras@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Tadej Teršek
tadej.tersek@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

KLJUČNE BESEDE

centralizirano načrtovanje poti, distribuirano načrtovanje poti, usklajevanje agentov, izogibanje trkom, optimizacija poti

1 UVOD

V tem članku obravnavamo problem več-agentnega iskanja poti (Multi-Agent Path Finding / MAPF), ki se v praksi pojavlja v številnih domenah, kot so robotizirana skladišča, avtonomna vozila, inteligentni transportni sistemi in drugi logistični sistemi. Gre za temeljni problem koordinacije več avtonomnih enot v skupnem prostoru, kjer mora vsak agent doseči svoj cilj brez trkov z drugimi agenti ali ovirami.

Cilj problema je načrtovati poti za množico agentov v diskretnem prostoru tako, da se izognemo medsebojnim konfliktom in hkrati optimiziramo določene metrike, kot sta skupni čas izvajanja (ang. *makespan*) ali vsota dolžin poti (ang. *sum of costs*). [9]

Repozitorij z izvorno kodo projekta je na voljo na naslovu: https://github.com/Asos75/MultiAgent.

Kot osnovo za formalno definicijo problema in uporabljene metrike uporabljamo delo *Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks* [9]. Poudarjamo, da omenjeni članek ne predstavlja konkretnega algoritma, temveč služi kot referenčni okvir za definicije problema MAPF, njegove različice ter standardne metrike, ki jih uporabljajo v nadaljevanju omenjeni članki in katere bomo uporabili tudi mi.

Za analizo bomo uporabili več sodobnih znanstvenih člankov, ki obravnavajo različne pristope k reševanju problema MAPF. Izbrane članke so identificirali posamezni člani skupine:

- *LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding* [6] (Šošterič),
- *Priority-Based Search for Multi-Agent Path Finding* [5] (Lipavec),
- *Follower: Learning to Solve Decentralized Lifelong Multi-Agent Pathfinding* [1] (Teršek),
- *MATS-LP: Learning Decentralized Multi-Agent Pathfinding with Transformer-Based Policies* [8] (Fras).

V nadaljevanju bomo primerjali centralizirane metode, katerih predstavnika sta LaCAM in PBS, ki načrtujejo poti za vse agente z uporabo globalnega pogleda na problem, ter decentralizirane pristope, kot sta Follower in MATS-LP, kjer posamezni agenti sprejemajo odločitve lokalno brez centralnega nadzora in imajo pregled le nad svojo okolico.

Na ta način bomo analizirali ključne razlike med obema paradigmama z vidika učinkovitosti, skalabilnosti in kakovosti rešitev. Centralizirani pristopi praviloma zagotavljajo bolj optimalne rešitve, vendar slabše skalirajo z naraščajočim številom agentov, medtem ko decentralizirani pristopi omogočajo boljšo razširljivost, vendar pogosto na račun kakovosti rešitev.

Kot glavni referenčni algoritem izberemo delo *LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding* [6], ki predstavlja sodoben in učinkovit centraliziran pristop k reševanju problema MAPF. Izbrani članek služi kot referenčna osnova za našo analizo, saj ponuja dobro ravnovesje med učinkovitostjo in skalabilnostjo ter omogoča relativno enostavno reprodukcijo eksperimentov.

LaCAM bomo uporabili kot predstavnika centraliziranih metod, s katerim bomo primerjali decentralizirane pristope, kot sta Follower in MATS-LP, ter tako sistematično analizirali razlike med globalnim in lokalnim načrtovanjem poti.

1.1 Uvedba lokalnih vodij

Glavni prispevek tega dela je predlagana nadgradnja obstoječih pristopov, ki uvaja koncept *lokalnih vodij*. Gre za hibridni pristop med centraliziranim in decentraliziranim načrtovanjem, kjer je množica agentov razdeljena na lokalne skupine.

Namesto popolnoma globalnega načrtovanja za vse agente ali popolnoma neodvisnega lokalnega odločanja predlagamo hierarhično razporeditev agentov v več lokalnih skupin. Vsaka od teh skupin ima lokalnega vodjo, to je agent, ki koordinira agente znotraj skupine, reševanje lokalnih konfliktov ter usklajevanje prehodov skozi

kritične točke, kot so ozki hodniki, križišča ali območja z visoko gostoto agentov.

Za lažje razmevanje algoritma je priložen diagram poteka (Figure 1), ki prikazuje, razdelitev agentov v skupine, izbiro lokalnih vodij ter postopek lokalnega reševanja konfliktov in medskupinske koordinacije.

Lokalni vodja nima globalnega pogleda nad celotnim okoljem, temveč razpolaga le z informacijami o agentih znotraj svoje skupine in njihove neposredne okolice. Na ta način se bistveno zmanjša kompleksnost načrtovanja v primerjavi s centraliziranimi algoritmi, hkrati pa se ohrani višja stopnja koordinacije kot pri popolnoma decentraliziranih pristopih.

Predlagamo dva pristopa pri izbiri lokalnih vodij:

- **Statično**: Lokalni vodji so določeni vnaprej na podlagi kriterijev, kot so centralnost položaja,
- **Dinamično**: Lokalni vodji se določajo adaptivno med izvajanjem, glede na trenutno gostoto agentov in potrebe po koordinaciji.

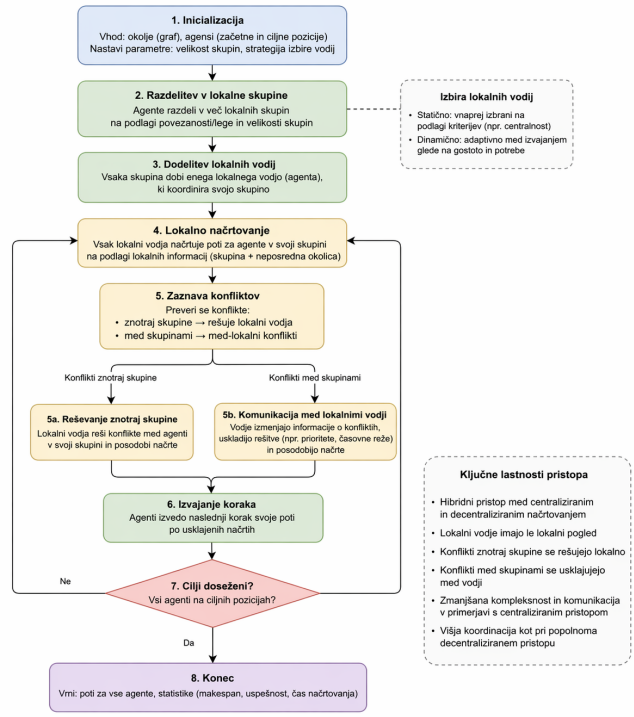

Slika 1: Diagram poteka algoritma, ki uporablja lokalne vodije

Ko pride do konflikta med agenti različnih skupin, lokalni vodije komunicirajo, med seboj in uskladijo rešitev konflikta, kar omogoča učinkovito koordinacijo brez potrebe po centralnem načrtovalcu. To zmanjša komunikacijsko obremenitev in poveča skalabilnost sistema.

Hipoteza našega dela je, da lahko takšen hibridni pristop doseže boljše razmerje med kakovostjo rešitev in časom načrtovanja kot obstoječi centralizirani ali decentralizirani pristopi posebej. Pričakujemo nižji *makespan* in višjo stopnjo uspeha kot pri decentraliziranih metodah ter bistveno krajši čas načrtovanja kot pri popolnoma centraliziranih algoritmih.

V eksperimentalnem delu bomo preverili vpliv različnih strategij izbire lokalnih vodij, velikosti skupin ter gostote agentov na uspešnost reševanja problema MAPF.

2 DEFINICIJA PROBLEMA

Stern et al. [9] definirajo problem več-agentnega iskanja poti (Multi-Agent Path Finding - MAPF) kot trojico

$$\langle G, s, t \rangle,$$

kjer je $G = (V, E)$ neusmerjen graf, pri čemer V predstavlja množico vozlišč, E pa množico povezav.

Podana je množica agentov $A = \{1, 2, \ldots, k\}$. Funkcija

$$s : \{1, \ldots, k\} \to V$$

preslika vsakega agenta v njegovo začetno vozlišče, funkcija

$$t : \{1, \ldots, k\} \to V$$

pa v njegovo ciljno vozlišče.

Naj bo $\pi_i[t] \in V$ položaj agenta i v diskretnem času $t \in \mathbb{N}_{\geq 0}$. Pri vsakem koraku t se agent i lahko premakne v sosednje vozlišče ali ostane na trenutnem, tj.

$$\pi_i[t+1] \in \text{neigh}(\pi_i[t]) \cup \{\pi_i[t]\},$$

kjer je $\text{neigh}(v)$ množica vozlišč, sosednjih vozlišču $v \in V$. [6]

Po Okamuri [6] se mora agent izogibati naslednjim vrstam konfliktov:

- **Vozliščni konflikt:** Do vozliščnega konflikta (ang. vertex conflict) pride, če nameravata π_i in π_j zasedeti isto vozlišče v istem trenutku, torej obstaja časovni korak t, da velja $\pi_i[t] = \pi_j[t]$. [9]
- **Zamenjalni konflikt:** Do zamenjalnega konflikta (ang. swap conflict) pride, če nameravata π_i in π_j zamenjati svoji poziciji v istem trenutku, torej obstaja časovni korak t, da velja $\pi_i[t] = \pi_j[t+1] \wedge \pi_i[t+1] = \pi_j[t]$. [9]

Rešitev MAPF za instance, omenjene zgoraj, je množica brezkonfliktnih poti $\{\pi_1, \ldots, \pi_k\}$ takih, da obstaja časovni korak $T \in \mathbb{N}_{\geq 0}$, kjer agent doseže cilj. [6]

3 SORODNA DELA

V tem razdelku izpostavimo ključna dela s področja več-agentnega iskanja poti, ki dopolnjujejo in razširjajo pogled iz uvoda.

3.1 Centralizirani pristopi

EECBS [4] predstavlja nadgradnjo klasičnega algoritma CBS (Conflict Based Search) pri čimer ohranja klasičen dvonivojski pristop, vendar uvaja uporabo *Explicit Estimation Search* (EES)

Algoritem omogoča nadzorovano suboptimalnost z uporabo uteži kar pomeni, da lahko uporabnik eksplicitno določi kompromis med kakovostjo rešitve in časom izvajanja. Rezulatati pa pokažejo, da algoritem presega klasični CBS pri večjih instancah (več sto agentov), pri čemer so rezultati dokazljivo slabši za največ 2 odstotka. Zaradi tega predstavlja pomembno referenčno točko pri primerjavi

z novejšimi algoritmi, kot so LaCAM in PBS, ki prav tako ciljajo na izboljšano skalabilnost.

CBSH2 [3] predstavlja izboljšano različico algoritma CBS, ki uvaja napredne hevristike za učinkovitejše preiskovanje iskalnega prostora. Ključna ideja je uporaba informiranih ocen stroška, ki upoštevajo strukturo konfliktov med agenti, kar omogoča boljše usmerjanje iskanja.

Algoritem uporablja tehniko razčlenjevanja konfliktov (ang. disjoint splitting), ki odpravlja pomanjkljivost klasičnega CBS, kjer lahko različne veje vsebujejo iste kandidatne rešitve. Z uvedbo pozitivnih omejitev ustvari dve disjunktni veji: v eni agentu prepove biti v konfliktni točki, v drugi pa ga tja prisili. S tem se izognemo podvajanju iskanja.

Posledično se zmanjša velikost iskalnega drevesa in število obravnavanih vozlišč, kar vodi do boljše časovne učinkovitosti in skalabilnosti v primerjavi z osnovnim CBS, zlasti pri večjem številu agentov.

3.2 Decentralizirani pristopi

Follower [1] je decentraliziran pristop k reševanju problema lifelong MAPF, ki temelji na kombinaciji hevristično načrtovane poti in naučene politike sledenja. Sistem je sestavljen iz dveh komplementarnih modulov.

Hevristični načrtovalec poti za vsakega agenta neodvisno zgradi pot od trenutne lokacije do cilja z algoritmom A*. Pri tem upošteva le statične ovire, ne pa tudi ostalih agentov, saj se izogibanje trkom prepusti drugemu modulu. Ključna lastnost načrtovalca je, da ne išče najkrajše poti, temveč enakomerno razpršene poti, s čimer zmanjša zasičenost na ozkih mestih karte (hodniki, vrata). To doseže z dvonivojskimi stroški prehoda: statični stroški temeljijo na topologiji karte in penalizirajo pogosto uporabljena vozlišča, dinamični stroški pa se tekom epizode posodabljajo glede na agentove lastne opazovalne izkušnje.

Modul za sledenje poti implementira naučeno politiko, ki agenta vodi vzdolž konstruirane poti in hkrati zagotavlja izogibanje trkom z ostalimi agenti. Politiko aproksimira globoka nevronska mreža, ki kot vhod sprejme lokalno opazovanje agenta v obliki 2D tenzorja dimenzije 2×m×m. Tenzor kodira lokacije statičnih ovir, trenutno pot in položaje ostalih agentov. Arhitektura mreže sestoji iz prostorskega koderja, ki mu sledita dve veji – akterska in kritična – obe z rekurenčnimi bloki GRU za modeliranje zgodovine opazovanj.

Sistem se uči z algoritmom PPO, kjer agent prejme nagrado za dosego naslednje točke na poti. Kadar se agent preveč oddalji od poti ali se ji preveč približa, se hevristični načrtovalec ponovno aktivira. Med decentraliziranim sklepanjem vsak agent uporablja kopijo naučenih uteži, kar omogoča enostavno skaliranje na poljubno število agentov brez potrebe po centralnem koordinatorju ali ekspertnih podatkih za učenje.

Decentralized Monte Carlo Tree Search for Partially Observable Multi-agent Pathfinding [8] predlaga decentralizirano rešitev problema lifelong MAPF v pogojih delne opazljivosti, kjer agenti nimajo dostopa do globalnega stanja okolja in zaznavajo le omejeno lokalno okolico. Namesto centraliziranega načrtovanja vsak agent samostojno zgradi intrinzični Markov odločitveni proces (ang. intrinsic MDP), ki predstavlja lokalno aproksimacijo večagentnega sistema na podlagi lokalnih opazovanj.

Na tako definiranem modelu agent izvaja prilagojeno različico Monte Carlo Tree Search (MCTS), podprto z nevronsko mrežo. Naučena politika usmerja raziskovanje možnih akcij, medtem ko simulacije v iskalnem drevesu omogočajo kratkoročno napovedovanje interakcij z bližnjimi agenti. Kombinacija iskalnega načrtovanja in podkrepitvenega učenja omogoča, da odločitve agentov niso zgolj reaktivne, temveč temeljijo na predvidenih prihodnjih stanjih okolja.

Koordinacija med agenti nastaja implicitno skozi simulacije v intrinzičnem MDP-ju, brez potrebe po globalnem koordinatorju ali eksplicitni komunikaciji. Kljub omejenim informacijam simulacije spodbujajo izogibanje trkom in kooperativno vedenje, kar zagotavlja dobro skalabilnost pri večjem številu agentov v dinamičnih scenarijih lifelong MAPF.

Avtorji so metodo ovrednotili na standardnih MAPF okoljih, vključno z naključnimi mrežami, labirinti in skladiščnimi scenariji. Rezultati so pokazali, da kombinacija nevronsko vodenega MCTS in lahke naučene politike izboljša pretočnost sistema in koordinacijo agentov, pri čemer presega zmogljivosti obstoječih decentraliziranih rešitev.

PRIMAL2 [2] predstavlja enega prvih uspešnih poskusov uporabe globokega podkrepitvenega učenja za MAPF. Nadgrajuje originalni PRIMAL z izboljšanimi mehanizmi učenja, vključno s kombinacijo *imitation learning* (na podlagi centraliziranih načrtovalcev) in *reinforcement learning*.

Ključna značilnost je učenje politike na osnovi lokalnih opazovanj, kar omogoča popolnoma decentralizirano izvajanje in zelo dobro skalabilnost tudi za velike sisteme agentov. PRIMAL2 dosega konkurenčne rezultate z obstoječimi metodami, zlasti v velikih in gostih okoljih, kjer centralizirani pristopi postanejo neučinkoviti.

Slabost pristopa je predvsem v slabši optimalnosti poti in občasnih neusklajenostih med agenti, saj lokalne informacije ne omogočajo popolne globalne koordinacije.

SCRIMP [10] uvaja komunikacijski mehanizem med agenti na osnovi transformer arhitekture. Agenti si izmenjujejo informacije preko pozornostnega mehanizma, kar omogoča učinkovito koordinacijo tudi pri zelo omejenem vidnem polju (npr. 3×3).

S tem pristop presega omejitve metod, ki temeljijo zgolj na lokalnih opazovanjih, saj agentom omogoča upoštevanje širšega konteksta. Posebej zasnovan komunikacijski mehanizem hkrati ohranja skalabilnost in zmanjšuje vpliv šuma v komunikaciji, kar vodi do boljše uspešnosti v primerjavi z obstoječimi učenimi pristopi.

3.3 Primerjalne platforme

POGEMA [7] ponuja standardizirano platformo za evalvacijo MAPF algoritmov, vključno z generatorjem instanc in enotnimi metrikami. Omogoča pošteno in ponovljivo primerjavo različnih pristopov, kar je ključno za našo eksperimentalno analizo.

4 NAČRT REŠITVE

V tem poglavju so navedena opravila, potrebna za implementacijo projekta, ki so razdeljena v štiri razvojne iteracije (sprinte). Predstavljena sta tudi časovni razpored v obliki Ganttovega (Table 1) diagrama, ter UML diagram predlagane rešitve (Figure 2).

- **Sprint 1:**

  - Ustvarjanje repozitorija Git za nalaganje, verzioniranje in usklajevanje programske kode.
  - Pisanje osnutka poglavja *Uvod* (predstavitev problema MAPF in motivacije).
  - Pisanje osnutka poglavja *Sorodna dela* (pregled algoritmov LaCAM, PBS, Follower in MATS-LP).
  - Pridobivanje in prenos izvorne kode izbranih centraliziranih in decentraliziranih algoritmov.
  - Osnovna analiza strukture implementacij.
  - Priprava eksperimentalnega okolja (namestitev POGEMA, nastavitev C++ in Python okolja).
- **Sprint 2:**
  - Dokončanje poglavij *Uvod* in *Sorodna dela*.
  - Pisanje poglavja *Metodologija* (definicija metrik: *SoC, makespan, uspešnost, čas*).
  - Začetek poglavja *Eksperiment in analiza rezultatov* (opis eksperimentalnega protokola, instanc in parametrov).
  - Reprodukcija rezultatov iz izbranih člankov na manjših instancah (validacija implementacij).
  - Implementacija lastne ideje:
    * zasnova enotnega evalvacijskega ogrodja (*pipeline*),
    * definicija skupnega vmesnika za integracijo algoritmov.
  - Implementacija eksperimentalnega ogrodja in osnovnih skript za zagon eksperimentov.
- **Sprint 3:**
  - Dokončanje poglavja *Metodologija*.
  - Nadaljevanje poglavja *Eksperiment in analiza rezultatov*.
  - Nadaljnja implementacija lastne ideje:
    * razdelitev agentov v lokalne skupine,
    * določitev lokalnih vodij,
    * implementacija lokalne koordinacije in reševanja konfliktov.
  - Implementacija metrik znotraj ogrodja (SoC, makespan, uspešnost, čas izvajanja).
  - Integracija vseh algoritmov v skupno ogrodje.
  - Zagon lastnega eksperimenta:
    * na lastni izboljšavi,
    * na izbranih instancah iz zbirk MovingAI in POGEMA,
    * pri različnih gostotah agentov in velikostih map.
- **Sprint 4:**
  - Dokončanje poglavja *Eksperimenti in analiza rezultatov*.
  - Pisanje poglavja *Zaključek*.
  - Pisanje poglavja *Povzetek*.
  - Podrobna analiza rezultatov na podlagi definiranih metrik.
  - Primerjava centraliziranih, decentraliziranih in hibridnega pristopa.
  - Identifikacija prednosti, slabosti in omejitev posameznih pristopov.
  - Izdelava vizualizacij (grafi in tabele).
  - Končna revizija članka in priprava za oddajo.

Tabela 1: Ganttov diagram razvoja po sprintih.

Naloga	Tedni							
	1	2	3	4	5	6	7	8
Sprint 1								
Ustvarjanje Git repozitorija	■							
Pisanje poglavja *Uvod*	■	■						
Pisanje poglavja *Sorodna dela*	■	■						
Pridobivanje programske kode	■							
Priprava eksperimentalnega okolja	■							
Sprint 2								
Dokončanje *Uvod* in *Sorodna dela*		■	■					
Pisanje *Metodologija*			■	■				
Opis eksperimenta			■	■				
Reprodukcija rezultatov				■				
Razvoj evalvacijskega ogrodja				■	■			
Sprint 3								
Dokončanje *Metodologija*					■			
Implementacija ideje in metrik					■	■		
Integracija algoritmov					■			
Zagon eksperimentov (MovingAI/POGEMA)						■	■	
Sprint 4								
Dokončanje *Eksperimenti in analiza*							■	■
Analiza rezultatov							■	■
Pisanje *Zaključek*								■
Pisanje *Povzetek*								■
Revizija in oddaja								■

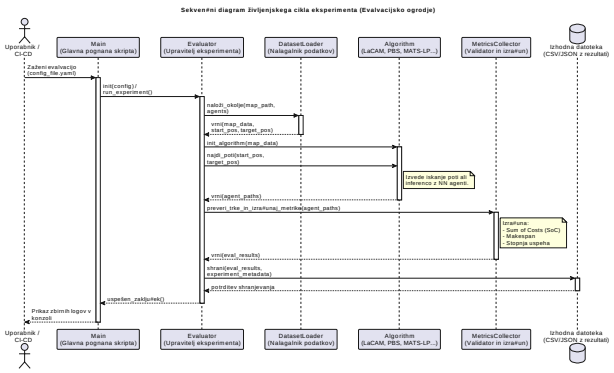

Slika 2: UML diagram (diagram primera uporabe / diagram razredov / sekvenčni diagram) predlagane rešitve.

5 METODOLOGIJA

V tem poglavju bomo predstavili metodologijo vrednotenja in primerjanja izbranih algoritmov za problem večagentnega iskanja poti. Cilj eksperimentalnega dela je primerjati centralizirane pristope, kot sta LaCAM in PBS, z decentraliziranimi pristopi Follower in MATS-LP ter ovrednotiti predlagani hibridni pristop z lokalnimi vodji.

5.1 Experimentalno okolje

Za primerjalno okolje bomo uporabili knjižnico POGEMA [7], ki omogoča standardizirano evalvacijo MAPF algoritmov v delno opazljivih okoljih, ter to kombinirali z MovingAI [9] knjižnico zemljevidov za testiranje agentov.

POGEMA je dostopna kot standardna Python knjižnica, medtem ko so implementacije posameznih algoritmov pridobljene iz uradnih repozitorijev avtorjev izbranih člankov. Ker različni algoritmi uporabljajo različne vhodne formate in interne predstavitve okolja, je bilo potrebno za vsako implementacijo razviti poseben prilagoditveni sloj (*adapter*), ki omogoča vključitev algoritma v skupno evalvacijsko ogrodje.

Kot primer integracije lahko izpostavimo algoritem LaCAM, ki je implementiran v C++, in uporablja lasten vhodni format na osnovi datotek *.map* in *.scen*. Ker pa POGEMA uporablja, drugačno predstavitev zemljevidov in agentov je bilo potrebno razviti poseben prilagoditveni sloj (ang. *adapter*), ki omogoča povezavo med obema sistemoma (Figure 3).

Ta od POGEMA pridobi mrežo ovir in trenutno stanje agentov in njihove ciljne pozicije, nato pa te podatke pretvori v v MovingAI format, ki ga zahteva LaCAM. Po pripravi vhodnih datotek se algoritem zažene kot zunanja binarna datoteka preko sistemskega klica.

Po zaključku izvajanja adapter prebere rezultat iz izhodne datoteke, razčleni izračunane poti agentov skozi posamezne časovne korake ter jih pretvori nazaj v zaporedje akcij, združljivo z okoljem POGEMA. Na ta način je mogoče centralizirani algoritem izvajati znotraj istega eksperimentalnega ogrodja kot decentralizirane pristope, kar omogoča neposredno in pošteno primerjavo vseh metod.

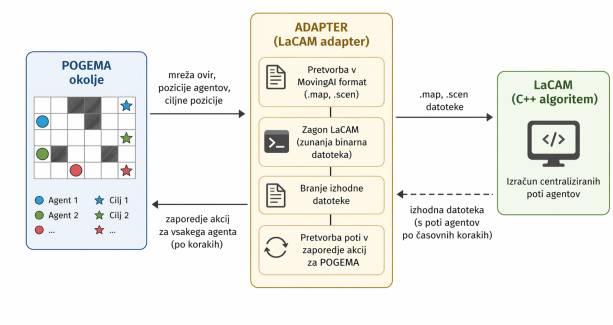

Slika 3: Shema adapterja za integracijo zunanjih MAPF implementacij v evalvacijsko ogrodje POGEMA.

5.2 Metrike

Sum-of-Costs (SoC) je vsota časovnih korakov, ki jih vsi agenti porabijo za dosego svojih ciljnih vozlišč [9]:

$$\text{SoC} = \sum_{i=1}^{k} |\pi_i|,$$

kjer je $|\pi_i|$ dolžina poti agenta i. Nižja vrednost pomeni učinkovitejšo rešitev.

SoC je ena izmed najpogosteje uporabljenih metrik v MAPF literaturi [9], kar omogoča neposredno primerjavo z obstoječimi deli. Metrika meri skupni strošek kot vsoto dolžin poti vseh agentov in s tem neposredno zajame celostno učinkovitost sistema.

Metrika je še posebej primerna za one-shot scenarije, saj minimizacija SoC ustreza cilju minimizacije skupne porabe časa oziroma virov. Hkrati kaznuje neučinkovite poti posameznih agentov, kar spodbuja iskanje globalno učinkovitih rešitev. SoC bomo zato uporabili za vrednotenje algoritmov LaCAM in PBS na zbirki MovingAI.

Makespan je čas, ki ga porabi najdaljša pot med vsemi agenti, torej maksimum nad vsemi $|\pi_i|$ [9]:

$$\text{makespan} = \max_{i \in \{1,\ldots,k\}} |\pi_i|.$$

Metrika odraža skupno trajanje reševanja instance in je primerna za scenarije, kjer je ključen vzporedni zaključek vseh agentov. Makespan je uveljavljena metrika v MAPF literaturi [9] in je še posebej relevantna v praktičnih aplikacijah, kjer je ključen vzporedni zaključek vseh agentov.

Makespan je pri primerjavi centraliziranih algoritmov nujna dopolnitev k SoC, saj sama vsota stroškov namreč ne razkrije, ali posamezen agent morda bistveno zavlačuje celotno skupino. Z vključitvijo obeh metrik tako dobimo celovitejšo in bolj zanesljivo oceno učinkovitosti algoritma v realnih pogojih.

Stopnja uspeha (Success Rate) meri delež instanc, pri katerih vsi agenti uspešno dosežejo svoje cilje znotraj predvidenega časovnega horizonta [7].

Stopnja uspeha je primarna metrika platforme POGEMA in skupaj s pretokom (ang. throughput) tvori osnovo za vrednotenje na tej platformi [7]. Zasnovana je posebej za vrednotenje decentraliziranih metod v delno opazljivih okoljih. Metrika je za naš eksperiment ključna, saj za razliko od SoC in makespana meri tudi robustnost algoritma oziroma njegovo sposobnost, da instanco v celoti reši kljub omejenim lokalnim opazovanjem.

Čas načrtovanja merimo kot skupni čas izvajanja algoritma na posamezni instanci. Ta metrika je še posebej pomembna pri primerjavi med kategorijama, saj centralizirani načrtovalec tipično porabi več časa za globalno načrtovanje, kot decentralizirani agenti.

Čas načrtovanja je v praktičnih aplikacijah enako pomemben kot kakovost rešitve, saj algoritem z optimalno potjo, a dolgim časom načrtovanja, v realnih sistemih ni uporaben. Ta metrika nam tako omogoča primerjavo med pristopoma z vidika razširljivosti in praktične uporabnosti.

5.3 Protokol primerjave

Primerjavo bomo izvedli na dveh ravneh:

(1) **Znotraj kategorije:** LaCAM in PBS primerjamo na MovingAI zbirki po metrikah SoC, makespan in čas načrtovanja. Follower in MATS-LP primerjamo na POGEMA zbirki po metrikah throughput in stopnja uspeha.
(2) **Med kategorijama na skupni zbirki:** Obe katergoriji bomo primerjali med seboj na skupni zbirki, kjer bomo primerjali prej navedene metrike.

6 EKSPERIMENT IN ANALIZA REZULTATOV

V tem poglavju predstavljamo eksperimentalni protokol, začetno reprodukcijo rezultatov iz izbranih člankov ter zasnovo lastnega eksperimenta za primerjavo centraliziranih, decentraliziranih in lastnega hibridnega pristopa reševanja problema MAPF.

6.1 Reprodukcija rezultatov iz literature

Pred izvedbo lastnih eksperimentov smo najprej reproducirali osnovne rezultate iz izbranih člankov, saj je to potrebno za validacijo implementacij in preverjanje pravilnosti eksperimentalnega okolja.

Pri algoritmu LaCAM smo uporabili uradno implementacijo algoritma [6] ter testne primere iz zbirke MovingAI. Posebej smo preverjali metriki *sum-of-costs* in *makespan* pri različnih gostotah agentov na standardnih grid zemljevidih. Cilj reprodukcije ni bila popolna identčna rekonstrukcija vseh rezultatov članka, temveč preverjanje, ali se dobljeni rezultati nahajajo v primerljivem območju glede kakovosti rešitev in časa izvajanja.

Pri algoritmu PBS

Pri decentraliziranih metodah Follower [1] in MATS-LP [8]

6.2 Lastni eksperiment

Po začetni validaciji implementacij smo zasnovali lasten eksperiment, ki bo primerjal centralizirane, decentralizirane in hibridni pristop z lokalnimi vodji. Namen experimenta je preveriti ali lahko uvedba lokalnih vodij izboljša razmerje med kakovostjo rešitev in časom načrtovanja.

Experimente izvajamo na standardiziranih zemlevidih iz zbirk MovingAI in POGEMA, na različnih velikostih zemljevidov, gostotah agentov in scenarijih. Tu so najbolj zanimivi scenariji z visoko gostoto agentov, kjer se razlike med rešitvami najbolj pokažejo.

6.2.1 Testne instance. Uporabljamo tri glavne tipe okolij:

- **Odprte mreže** (*random grids*) – okolja z malo ovirami, kjer je večina konfliktov posledica visoke gostote agentov.
- **Labirinti** (*mazes*) – okolja z ozkimi prehodi in številnimi lokalnimi ozkimi grli, kjer je koordinacija agentov bistveno zahtevnejša.
- **Skladiščni scenariji** (*warehouse maps*) – realistične postavitve, podobne robotiziranim skladiščem, kjer se agenti pogosto srečujejo na križiščih in v ozkih hodnikih.

Kot zanimiv prikaz dejanske uporabe pa uporabljamo tudi:

- **Zemljevide mesta** (*city maps*) – Resnični zemljevide mest, ki vključujejo ulice, zgradbe in druge ovire.
- **Zemlevid videoiger** (*game maps*) – Zemljevidi iz videoiger, ki pogosto vključujejo kompleksne strukture, hodnike in ovire.

Za vsako vrsto okolja izvajamo eksperimente pri različnih številih agentov (od 20 do 1000 agentov, odvisno od velikosti zemljevida), z različnimi konfiguracijami. Vsaka konfiguracija se izvede večkrat z različnimi scenariji, ki vključujejo začetne in ciljne pozicije agentov, rezultati pa se povprečijo, da zmanjšamo vpliv posameznih naključnih primerov.

6.2.2 Predlagani hibridni pristop. Pri lastni izboljšavi uvedemo hierarhično razdelitev agentov v lokalne skupine. Skupine oblikujemo na podlagi prostorske bližine agentov ter njihove trenutne gostote v okolju.

Vsaki skupini dodelimo lokalnega vodjo, ki prevzame odgovornost za:

- koordinacijo gibanja znotraj skupine,
- lokalno reševanje konfliktov,
- usklajevanje prehodov skozi ozke prehode,
- komunikacijo z drugimi lokalnimi vodji ob medskupinskih konfliktih.

Eksperimentalno preverjamo dve strategiji izbire lokalnih vodij:

- **Statična izbira**, kjer vodje določimo pred začetkom izvajanja na podlagi centralnosti položaja;
- **Dinamična izbira**, kjer se vodje prilagajajo med izvajanjem glede na trenutno gostoto agentov in konfliktne situacije.

Dodatno analiziramo vpliv velikosti skupin na uspešnost algoritma, saj premajhne skupine zmanjšajo prednosti koordinacije, prevelike pa povečajo lokalno kompleksnost načrtovanja.

6.2.3 Primerjalni kriteriji. Primerjavo izvajamo med tremi kategorijami pristopov:

(1) **Centralizirani pristopi** (LaCAM, PBS),
(2) **Decentralizirani pristopi** (Follower, MATS-LP),
(3) **Hibridni pristop** (lokalni vodje).

Za vse metode spremljamo naslednje metrike:

- **SoC**,
- **makespan**,
- **stopnja uspeha**,
- **čas načrtovanja**.

Pri decentraliziranih metodah dodatno spremljamo tudi *throughput*, saj je ta metrika posebej pomembna pri lifelong MAPF scenarijih.

Posebej nas zanima:

- kako hitro začne kakovost centraliziranih metod padati zaradi časovne zahtevnosti,
- pri kateri gostoti agentov decentralizirani pristopi izgubijo stabilnost,
- ali hibridni pristop uspe ohraniti dobro kakovost rešitev ob bistveno krajšem času načrtovanja.

6.3 Rezulatati

LITERATURA

[1] Anton Andreychuk, Konstantin Yakovlev, Alexey Skrynnik, and Aleksandr Panov. 2024. Follower: Learning to Solve Decentralized Lifelong Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*. AAAI Press.

[2] Mehul Damani, Zhiyao Luo, Emerson Wenzel, and Guillaume Sartoretti. 2021. PRIMAL$_2$: Pathfinding via Reinforcement and Imitation Multi-Agent Learning — Lifelong. *IEEE Robotics and Automation Letters* 6, 2 (2021), 2666–2673. https://doi.org/10.1109/LRA.2021.3062803

[3] Jiaoyang Li, Daniel Harabor, Peter J. Stuckey, Ariel Felner, Hang Ma, and Sven Koenig. 2019. Disjoint Splitting for Multi-Agent Path Finding with Conflict-Based Search. 29 (Jul. 2019), 279–283. https://doi.org/10.1609/icaps.v29i1.3487

[4] Jiaoyang Li, Wheeler Ruml, and Sven Koenig. 2021. EECBS: A Bounded-Suboptimal Search for Multi-Agent Path Finding. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*. 12353–12362. https://doi.org/10.1609/aaai.v35i14.17466

[5] Hang Ma, Daniel Harabor, Peter J. Stuckey, Jiaoyang Li, and Sven Koenig. 2019. Searching with consistent prioritization for multi-agent path finding. In *Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence and Thirty-First Innovative Applications of Artificial Intelligence Conference and Ninth AAAI Symposium on Educational Advances in Artificial Intelligence* (Honolulu, Hawaii, USA) *(AAAI'19/IAAI'19/EAAI'19)*. AAAI Press, Article 938, 8 pages. https://doi.org/10.1609/aaai.v33i01.33017643

[6] Keisuke Okumura. 2023. LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37. AAAI Press, 11655–11662. https://doi.org/10.1609/aaai.v37i10.26377

[7] Alexey Skrynnik, Anton Andreychuk, Anatolii Borzilov, Alexander Chernyavskiy, Konstantin Yakovlev, and Aleksandr Panov. 2025. POGEMA: A Benchmark

Platform for Cooperative Multi-Agent Pathfinding. In *The Thirteenth International Conference on Learning Representations*.

[8] Alexey Skrynnik, Anton Andreychuk, Konstantin Yakovlev, and Aleksandr Panov. 2024. Decentralized Monte Carlo Tree Search for Partially Observable Multi-Agent Pathfinding. In *Proceedings of the Thirty-Eighth AAAI Conference on Artificial Intelligence (AAAI-24)*. AAAI Press.

[9] Roni Stern, Nathan Sturtevant, Ariel Felner, Sven Koenig, Hang Ma, Thayne Walker, Jiaoyang Li, Dor Atzmon, Liron Cohen, T. Kumar, and Eli Boyarski. 2021. Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks. *Proceedings of the International Symposium on Combinatorial Search* 10 (09 2021), 151–158. https://doi.org/10.1609/socs.v10i1.18510

[10] Yutong Wang, Bairan Xiang, Shao Huang, and Guillaume Sartoretti. 2023. SCRIMP: Scalable Communication for Reinforcement- and Imitation-Learning-Based Multi-Agent Pathfinding. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. https://doi.org/10.1109/IROS55552.2023.10341379