Primerjava centraliziranega in distribuiranega večagentnega iskanja poti

Andraž Šoštarič
andraz.sosteric@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

David Lipavec
david.lipavec@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Nejc Fras
nejc.fras@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

Tadej Teršek
tadej.tersek@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

KLJUČNE BESEDE

centralizirano načrtovanje poti, distribuirano načrtovanje poti, usklajevanje agentov, izogibanje trkom, optimizacija poti

1 UVOD

V tem članku obravnavamo problem več-agentnega iskanja poti (Multi-Agent Path Finding - MAPF), ki se pojavlja tudi v resničnem svetu, kot so roboti v skladiščih, avtonomna vozila in podobnih logističnih sistemih.

Cilj problema je načrtovati poti za več agentov v skupnem prostoru tako, da se izognejo konfliktom in hkrati optimizirajo določeno metriko, kot je skupni čas ali dolžina poti.

Repozitorij z izvorno kodo je na voljo na naslovu: https://github.com/Asos75/MultiAgent.

Za analizo bomo uporabili več sodobnih znanstvenih člankov, ki obravnavajo različne pristope k reševanju problema več-agentnega iskanja poti (MAPF). Kot osnovo za definicijo problema uporabljamo delo *Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks* [9], ki sistematično opredeli različice problema in standardne metrike.

V nadaljevanju bomo primerjali centralizirane metode, kot sta *LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding* [6] in *Priority-Based Search for Multi-Agent Path Finding* [3], ki načrtujeta poti za vse agente z uporabo globalnega pogleda na problem.

Poleg tega bomo analizirali tudi decentralizirane pristope, kot sta *Follower: Learning to Solve Decentralized Lifelong Multi-Agent Pathfinding* [1] in *MATS-LP: Learning Decentralized Multi-Agent Pathfinding with Transformer-Based Policies* [8], kjer agenti sprejemajo odločitve lokalno brez centralnega nadzora.

Na ta način bomo lahko primerjali prednosti in slabosti centraliziranih in decentraliziranih pristopov z vidika učinkovitosti, skalabilnosti in kakovosti rešitev.

2 DEFINICIJA PROBLEMA

Stern et al. [9] definirajo problem več-agentnega iskanja poti (Multi-Agent Path Finding - MAPF) kot n-terico

$$\langle G, s, t \rangle,$$

kjer je $G = (V, E)$ neusmerjen graf, pri čemer V predstavlja množico vozlišč, E pa množico povezav.

Podana je množica agentov $A = \{1, 2, \ldots, k\}$. Funkcija

$$s : \{1, \ldots, k\} \to V$$

preslika vsakega agenta v njegovo začetno vozlišče, funkcija

$$t : \{1, \ldots, k\} \to V$$

pa v njegovo ciljno vozlišče.

Naj bo $\pi_i[t] \in V$ položaj agenta i v diskretnem času $t \in \mathbb{N}_{\geq 0}$. Pri vsakem koraku t se agent i lahko premakne v sosednje vozlišče ali ostane na trenutnem, tj.

$$\pi_i[t+1] \in \text{neigh}(\pi_i[t]) \cup \{\pi_i[t]\},$$

kjer je $\text{neigh}(v)$ množica vozlišč, sosednjih vozlišču $v \in V$. [6]

Po Okamura [6] se mora agent izogibati naslednjim vrstam konfliktov:

- **Vozliščni konflikt:** Do vozliščnega konflikta (ang. vertex conflict) pride, če nameravata π_i in π_j zasedeti isto vozlišče v istem trenutku, torej obstaja časovni korak t, da velja $\pi_i[t] = \pi_j[t]$. [9]
- **Zamenjalni konflikt:** Do zamenjalnega konflikta (ang. swap conflict) pride, če nameravata π_i in π_j zamenjati svoji poziciji v istem trenutku, torej obstaja časovni korak t, da velja $\pi_i[t] = \pi_j[t+1] \wedge \pi_i[t+1] = \pi_j[t]$. [9]

Rešitev MAPF za instance, omenjene zgoraj, je množica brezkonfliktnih poti $\{\pi_1, \ldots, \pi_k\}$ takih, da obstaja časovni korak $T \in \mathbb{N}_{\geq 0}$, kjer agent doseže cilj. [6]

3 SORODNA DELA

Na področju MAPF obstajata dva pristopa centralizirani in decentralizirani. Centralizirani pristopi imajo centralnega načrtovalca, ki ima globalni pogled na okolje, medtem ko decentralizirani pristopi vsakega agenta usposabljajo, da se odloča samostojno na podlagi lokalnih opazovanj.

3.1 Centralizirani pristopi

Med centraliziranimi pristopi je skupina algoritmov, ki temelji na iskanju v prostoru omejitev. *EECBS* [4] pohitri klasično CBS-iskanje z uporabo *Explicit Estimation Search* na visoki ravni in *focal search* na nizki ravni. Za razliko od optimalnih metod zagotavlja le garantiran suboptimalnostni faktor w, kar mu v zameno omogoča bistveno hitrejše reševanje pri večjem številu agentov.

Alternativno smer predstavlja *RHCR* [5], ki naslavlja lifelong različico problema, kjer agenti neprekinjeno prejemajo nove cilje. Problem razgradi na zaporedje omejenih MAPF instanc, pri čemer vsaka zajema le naslednje W časovnih korakov. Ta pristop omogoča hitro ponovni načrt brez reševanja celotnega horizonta in je posebej primeren za dinamična skladiščna okolja.

3.2 Decentralizirani pristopi

Pionirsko delo na področju učenja decentraliziranih politik je *PRIMAL2* [2], ki razširja izvirni PRIMAL z eksplicitnim modeliranjem hodniških situacij in podporo za lifelong scenarije. PRIMAL2 je porazdeljen okvir za spodbujevalno učenje pri LMAPF, kjer se agenti naučijo popolnoma decentraliziranih politik za reaktivno načrtovanje poti v delno opazljivem svetu, kar mu omogoča razširljivost do 2048 agentov.

Na tej osnovi je bil razvit *SCRIMP* [10], ki doda globalni in lokalni komunikacijski mehanizem na osnovi modificiranega transformerja. Agenti se učijo individualnih politik, ki hkrati izkoriščajo bližnje in oddaljene informacije, kar zmanjša pogostost zastojev pri visokih gostotah agentov.

4 PREGLED OVREDNOTENJA

Za primerjavo izbranih algoritmov bomo uporabili standardne metrike s področja MAPF, ki so uveljavljene v obstoječi literaturi [7, 9]. Vrednotenje bo potekalo na dveh standardnih zbirkah testnih instanc: MovingAI MAPF benchmark [9] in POGEMA benchmark [7].

4.1 Metrike

Sum-of-Costs (SoC) je vsota časovnih korakov, ki jih vsi agenti skupaj porabijo za dosego ciljev [9]:

$$\text{SoC} = \sum_{i=1}^{k} |\pi_i|,$$

kjer je $|\pi_i|$ dolžina poti agenta i. Nižja vrednost pomeni učinkovitejšo rešitev. To metriko bomo uporabili pri vrednotenju LaCAM in PBS na MovingAI zbirki za one-shot MAPF scenarije.

Makespan je čas, ki ga porabi najdaljša pot med vsemi agenti, torej maksimum nad vsemi $|\pi_i|$ [9]:

$$\text{makespan} = \max_{i \in \{1,\ldots,k\}} |\pi_i|.$$

Metrika odraža skupno trajanje reševanja instance in je primerna za scenarije, kjer je ključen vzporedni zaključek vseh agentov.

Stopnja uspeha (Success Rate) meri delež instanc, pri katerih vsi agenti uspešno dosežejo svoje cilje znotraj predvidenega časovnega horizonta [7]. Skupaj s throughputom tvori osnovo za vrednotenje decentraliziranih metod na POGEMA platformi.

Čas načrtovanja merimo kot skupni čas izvajanja algoritma na posamezni instanci. Ta metrika je posebej relevantna za primerjavo med kategorijama, saj centralizirani planner tipično porabi več časa za globalno načrtovanje, medtem ko decentralizirani agenti odločitve sprejemajo lokalno in vzporedno.

4.2 Protokol primerjave

Primerjavo bomo izvedli na dveh ravneh:

(1) **Znotraj kategorije:** LaCAM in PBS primerjamo na MovingAI zbirki po metrikah SoC, makespan in čas načrtovanja. Follower in MATS-LP primerjamo na POGEMA zbirki po metrikah throughput in stopnja uspeha.
(2) **Med kategorijama na skupni zbirki:** Obe katergoriji bomo primerjali med seboj na skupni zbirki, kjer bomo primerjali prej navedene metrike.

LITERATURA

[1] Anton Andreychuk, Konstantin Yakovlev, Alexey Skrynnik, and Aleksandr Panov. 2024. Follower: Learning to Solve Decentralized Lifelong Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*. AAAI Press.

[2] Mehul Damani, Zhiyao Luo, Emerson Wenzel, and Guillaume Sartoretti. 2021. PRIMAL$_2$: Pathfinding via Reinforcement and Imitation Multi-Agent Learning — Lifelong. *IEEE Robotics and Automation Letters* 6, 2 (2021), 2666–2673. https://doi.org/10.1109/LRA.2021.3062803

[3] Jiaoyang Li, Daniel Harabor, Peter J. Stuckey, Hang Ma, and Sven Koenig. 2019. Priority-Based Search for Multi-Agent Path Finding. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 33. AAAI Press, 181–188. https://doi.org/10.1609/aaai.v33i01.3301181

[4] Jiaoyang Li, Wheeler Ruml, and Sven Koenig. 2021. EECBS: A Bounded-Suboptimal Search for Multi-Agent Path Finding. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 35. 12353–12362. https://doi.org/10.1609/aaai.v35i14.17341

[5] Jiaoyang Li, Andrew Tinka, Scott Kiesel, Joseph W. Durham, T. K. Satish Kumar, and Sven Koenig. 2021. Lifelong Multi-Agent Path Finding in Large-Scale Warehouses. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 35. 11272–11281. https://doi.org/10.1609/aaai.v35i13.17344

[6] Keisuke Okumura. 2023. LaCAM: Search-Based Algorithm for Quick Multi-Agent Pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37. AAAI Press, 11655–11662. https://doi.org/10.1609/aaai.v37i10.26377

[7] Alexey Skrynnik, Anton Andreychuk, Anatolii Borzilov, Alexander Chernyavskiy, Konstantin Yakovlev, and Aleksandr Panov. 2024. POGEMA: A Benchmark Platform for Cooperative Multi-Agent Navigation. arXiv:2407.14931 [cs.LG] https://arxiv.org/abs/2407.14931

[8] Alexey Skrynnik, Anton Andreychuk, Konstantin Yakovlev, and Aleksandr Panov. 2023. MATS-LP: Learning Decentralized Multi-Agent Pathfinding with Transformer-Based Policies. *arXiv preprint arXiv:2312.15908* (2023).

[9] Roni Stern, Nathan Sturtevant, Ariel Felner, Sven Koenig, Hang Ma, Thayne Walker, Jiaoyang Li, Dor Atzmon, Liron Cohen, T. K. Satish Kumar, Eli Boyarski, and Roman Bartak. 2019. Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks. *arXiv preprint arXiv:1906.08291* (2019). https://doi.org/10.48550/arXiv.1906.08291 Accepted to SoCS 2019: The 12th Annual Symposium on Combinatorial Search.

[10] Yutong Wang, Bairan Xiang, Shao Huang, and Guillaume Sartoretti. 2023. SCRIMP: Scalable Communication for Reinforcement- and Imitation-Learning-Based Multi-Agent Pathfinding. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. https://doi.org/10.1109/IROS55552.2023.10341379